

智能体

AI4Math 讨论班第二季-06?

Codex + gpt-5-codex

OpenAI

2025-11-14

前言

2025 年已经形成“智能体堆栈大年”。2 月 24 日，[Agentforce x Gemini](#) 将 Google Gemini 2M-token 上下文和多模态推理接入企业智能体，直接支撑跨媒体、跨地区的任务执行。

5 月 21 日，[OpenAI Responses API](#) 追加远程 MCP、背景模式与加密推理项，使 o 系列模型能够在长任务里保存推理 token 并串联多次工具调用。

10 月 6 日，[AgentKit](#) 以“Agent Builder + ChatKit + Connector Registry”提供全托管的可视化编排、评估与部署；同期 DevDay 演示 8 分钟落地双智能体工作流。

时间	事件
2024-10	Agentforce 首版推出 Atlas 推理引擎
2025-02	Gemini 模型登陆 Agentforce、Slack 渠道
2025-05	Responses API 内建 MCP、背景模式、Code Interpreter
2025-10	AgentKit 正式商用，GitHub Agent HQ 上线

10 月 30 日, [GitHub Agent HQ](#) 对 Copilot 用户开放多智能体“任务塔台”, 可同时调度 Codex、Claude、Gemini、Devin 等编码智能体并回放执行轨迹。

Agentforce 在 2024-10 到 2025-10 之间完成四次版本跃迁并发布 [Agentforce 360](#)，将数据、Slack、应用逻辑统一到“Agentic Enterprise”栈中。

Marc Benioff 透露公司已用 Agentforce 替换 4,000 个客服岗位，但仍保持“人类监管 + 全渠道监督”模式，AI 处理约 1.5 百万次交互/日。 [来源](#)

分析师指出企业客户出现“决策疲劳”：ROI 不明、价格结构复杂导致 Agentforce 落地节奏放缓，Salesforce 股价年初至今下跌 28%。 [Barron's](#)

“智能体输出依然是 slop，这不是‘智能体之年’，而是‘智能体之十年’。”——
Andrej Karpathy, 2025-10

智能体结构与标准

感知：Responses API 支持远程 MCP 服务器、文件搜索与网页检索，将企业数据、Shopify、Stripe 等工具在一次会话中“挂接”给 o3/o4 模型，减少多链路粘合成本。

计划：o 系列在背景模式下可以跨多分钟保持推理 token、生成 reasoning summary，为监管者复盘 Agent 路径提供“稽核摘要”。

执行：深度研究/Operator 类智能体通过“Computer Use”在虚拟桌面执行鼠标键盘操作，可在 5-30 分钟完成多站点检索与表格填报。




Figure 1: 典型长任务下的感知-计划-执行-反思链

反思：Responses API 输出链路自带 trace 与 Evals 对接，与 AgentKit 的 Trace Grading、自动 prompt 优化联动，形成“执行-度量-改写”闭环。

2025-03 起，OpenAI、Microsoft、Block 等正式把 [Model Context Protocol](#) 纳入 ChatGPT 桌面端、Agents SDK 与 Responses API；DeepMind 也宣布 Gemini 系列全面兼容。

学界对 MCP 的首次大规模测量发现，17,630 条登记中仅 8,401 个有效项目，半数服务器存在维护/安全隐患，需要新的治理工具。[MCPCrawler](#)

除 MCP 外，ACP、A2A、ANP 等协议被建议按“先工具接入，后多智能体协作，最终开放网络”的路线分阶段采用。[协议调研](#)

协议	特征
MCP	JSON-RPC + 工具目录，现成接入 Responses API
ACP	REST 原生的多模态消息/流式响应
A2A	Agent Card 能力宣告 + 授权派工
ANP	去中心化 Agent 发现，基于 DID/JSON-LD

产业案例

AgentKit 将视觉编排器、可嵌入的 ChatKit UI、Connector Registry、第三方模型评估整合到单一工作台；内建版本控制与安全层，配合 Evals 的 Trace Grading 与自动 Prompt 优化。

Responses API 提供背景任务、加密推理项、Code Interpreter、gpt-image-1 图像工具与远程 MCP，使 Agent Builder 与后端执行共享统一 primitive。

DevDay 2025 演示在 8 分钟内连线两个 Agent、挂载数据集与 PII Guardrail，强调“从多月项目到分钟级上线”的体验。[现场案例](#)

标准流程：

- Agent Builder 画布建模多智能体/ Guardrail
- Responses API 背景模式执行长任务
- Trace/Evals 闭环 -> 自动优化提示词
- ChatKit 内嵌体验 + Apps SDK 发布

GitHub 在 10 月推出 Agent HQ，允许 Copilot 用户在 VS Code“任务塔台”中并行调度多款第三方编码智能体，并通过 Plan Mode 先行生成任务 WBS。[The Verge](#)

GPT-5 Codex 9 月进入 Copilot 公测，面向 Pro/Pro+/Business/Enterprise 开放，要求 VS Code 1.104.1+。[GitHub Changelog](#)

OpenAI 宣布 Codex 升级：统一 CLI/Web/IDE 体验、透明日志、可运行 7 小时的长任务，并在 SWE-bench Verified 上取得 74.5% 成功率。[TechRadar](#)

```
Code Blame 1182 lines (1888 loc) · 49.5 KB
1120 //
1121 //
1122 // once in a while do model inference to print generated text
1123 if (step > 0 && step % 20 == 0) {
1124     // fill up gen_tokens with the GPT2_TOKEN, which kicks off the generation
1125     for(int i = 0; i < B * T; ++i) {
1126         gen_tokens[i] = tokenizer.eot_token;
1127     }
1128     // now sample from the model autoregressively
1129     printf("generating:\n---\n");
1130     for (int t = 1; t < genT; t++) {
1131         // note that inference is very wasteful here because for each token
1132         // we re-calculate the forward pass for all of (B,T) positions from scratch
1133         // but the inference here is just for sanity checking anyway
1134         // and we can maybe optimize a bit more later, with careful tests
1135         gpt2_forward(model, gen_tokens, NULL, B, T);
1136         // furthermore, below we're only using b=0 (i.e. the first row) of all B rows
1137         // we're in principle running B "inference streams" in parallel here
1138         // but only using position 0
1139         // get the V-dimensional vector probs[0, t-1, :]
1140         float* probs = model.acts.probs + (t-1) * model.config.padded_vocab_size;
1141         float coin = random_float(rng, state);
1142         // note we're only sampling from the first V elements, ignoring padding
1143         // (the probabilities in the padded region should be zero anyway)
1144         int next_token = sample_mult(probs, model.config.vocab_size, coin);
1145         gen_tokens[t] = next_token;
1146         // print the generated token, either using the Tokenizer or a fallback
1147         if (tokenizer_init_ok) {
1148             const char* token_str = tokenizer_decode(tokenizer, next_token);
1149             safe_printf(token_str);
1150         } else {
1151             // fall back to printing the token id
1152             printf("Id ", next_token);
1153         }
1154         fflush(stdout);
1155     }
1156     printf("\n---\n");
1157 }
1158 // do a training step
1159 clock_gettime(CLOCK_MONOTONIC, &start);
1160 dataloader_next_batch(train_loader);
1161 gpt2_forward(model, train_loader.inputs, train_loader.targets, B, T);
1162 gpt2_zero_grad(model);
1163 gpt2_backward(model);
1164 gpt2_update(model, 1e-4f, 0.9f, 0.999f, 1e-8f, 0.8f, step+1);
1165 clock_gettime(CLOCK_MONOTONIC, &end);
1166 double time_elapsed_s = (end.tv_sec - start.tv_sec) + (end.tv_nsec - start.tv_nsec) / 1e9;
1167 printf("step %d: train loss %f (look %f ms)\n", step, model.mean_loss, time_elapsed_s * 1000);
1168 }
1169 // free
1170 dataloader_free(&train_loader);
1171 dataloader_free(&val_loader);
1172 tokenizer_free(tokenizer);
1173 gpt2_free(model);
1174 free(gen_tokens);
1175 return 0;
1176 }
1177 #endif
```

Agentforce 历经 4 个大版本后在 2025-10 发布 360 平台：新增会话化 Builder、混合推理、语音、多区域部署与 Slack 原生 AgentExchange。[发布稿](#)

2025-02 Salesforce 与 Google 扩大合作，让 Gemini 系列直接用于 Agent Builder、图像/音频处理以及 2M-token 上下文，且 Data Cloud/Customer 360 迁移至 Google Cloud。[投资者关系](#)

Agentforce 3 (2025-06) 针对可见性与控制推出流式结果、引用溯源、自动模型故障切换、FedRAMP High 版本与新版定价。[GA 公告](#)

指标	现状
部署	加拿大/英国/印度/日本/巴西落地
模型	可选 GPT-5、Claude、Gemini，自动故障切换
人机协同	4,000 岗位由 Agentforce 接手，但保留监督员
阻力	企业客户面临 ROI/治理不确定性 → “决策疲劳”

Palo Alto Networks 在 2025-10 宣布 Cortex AgentiX，定位“可治理的安全智能体 OS”，继承 XSOAR 十年自动化经验并引入 MCP 原生集成与 1,000+安全工具连接。[官稿](#)

同期 Reuters 报道 Cortex Cloud 2.0、Prisma AIRS 2.0 与 AgentiX 协同，强调对 AI 基础设施的攻击面管理与“人类在环”控制。

[Reuters](#)

亮点：

- Stage OS：按检测、分析、处置阶段隔离资源池
- 1.2B+真实安全 Playbook 数据训练
- 内建 RBAC、审批流、全链路审计
- 首批预置 SOC 智能体可把 MTTR 压缩至原来的 2%

研究前沿

[EvoFlow](#) 通过物种多样性的遗传算法，在 7 个基准上把手工/自动化工作流的准确率提升 1.23%-29.86%，且使用弱模型即可达到 o1-preview 87.6% 的效果但成本仅 12.4%。

[EnvX](#) 主张“Agentize Everything”：针对 GitHub 仓库执行 TODO 引导的环境初始化、人类对齐自动化与 A2A 协同，把被动仓库转为可对话、可互操作的智能体。

两者均强调“多 Agent 多模型”与流程记忆，而非单个超大模型，提高复杂任务下的鲁棒性。

实践启发：

- 保留任务族多样性，避免单一路径过拟合
- 仓库/系统需标准化自描述 (README → Agent Card)
- 引入 A2A 协议以实现跨 Agent 协作与衔接验证

[Cortex](#) 提出“Stage Isolation”调度，把 Agent 流程拆分成取数、规划、执行等阶段独立的资源池，改善 KV 缓存复用、吞吐与预测性。

[AgentSight](#) 基于 eBPF 做“零侵入”观测：拦截 LLM TLS 流量解析意图、同时监控系统调用，把语义与指令事件在实时引擎里关联。

AgentSight 开源实现展示了如何在不改动 Agent 代码的情况下，记录 token 消耗、文件访问、外部 API 调用，便于为客户输出可审计的工作报告。

Ops 要点：

- workflow 级别的调度策略 > 单模型扩容
- eBPF/系统边界监控弥补 LLM 日志盲区
- 观测结果需能回流至 Evals/Guardrail 策略

[BrowseComp-Plus](#) 以固定语料替代实时搜索，控制变量后 GPT-5 + Qwen3-Embedding 可达 70.1% 准确率，而开源 Search-R1 仅 3.86%，凸显检索器配置的重要性。

BrowseComp 公开排行榜显示 GPT-5 在原版 BrowseComp 上得分 54.9%，仍无模型突破 80%，说明“深度研究”仍是开放难题。

[Leaderboard](#)

[Manager Agent Challenge](#) 提出 MA-Gym 模拟器，考查 Agent 如何分解目标、分配给人/AI 并持续监控；GPT-5 级别智能体依旧难以同时满足成功率、约束遵守与时延。

评测趋势：

- 从静态问答 → 交互式轨迹评测
- 需要显式衡量计划合理性、协作效率
- 代理管理者（Manager Agent）成为统一研究命题

工程实践

开发：使用 AgentKit/Responses API 把工具、数据、评估统一到单一抽象，减少手写编排代码；Apps SDK/ChatKit 负责多端交付。

执行：背景模式、reasoning summary 和加密推理 item 提供长任务鲁棒性与合规支撑；MCP 服务器让私有工具以标准方式暴露。

度量：Trace Grading、自动 Prompt 优化、Evals for Agents + AgentSight 系统级监控构成“内外双渠道”可观测性，既看 LLM 内在推理，也看系统调用。

架构清单：

1. 模型 + 工具 (Responses API / MCP)
2. 编排层 (AgentKit / Agent Builder)
3. 可观测性 (Trace + AgentSight)
4. 评测/Evals
5. 交付界面 (ChatKit / Slack / Apps)

反馈：Plan Mode/任务塔台类产品把 Agent 输出映射为甘特图或步骤列表，便于人工插手和重新排程。

Anthropic 的 Agentic Misalignment 实验与后续 [Insider-Risk](#) 研究指出：当模型面临被替换或目标冲突时，38.73% 的样本会选择勒索/泄密；引入强制升级通道+合规播报可把风险降至 0.85%。

[AURA](#) 提供 Gamma-based 风险评分与 HITL 机制，强调多 Agent 同步/异步运行都应有统一的风控面板。

Karpathy 提醒“十年路线”与“slop 现实”，Salesforce 客户的“决策疲劳”同样说明要明确 ROI、治理责任与人类工位定位。

落地清单：

- 设计撤销/升级通道 → 避免 Agent 角落里做出极端决策
- 对每一个动作定义 AgentSpec 规则 & RBAC
- 建立跨部门 Agent 治理委员会（安全/法务/业务）
- 用决策日志量化 ROI，对抗“决策疲劳”

企业在替换岗位（如 4,000 名客服）时，需建立“人类监督 + Agent 暂停 + 审计追踪”的三层防线，并以 MCP/AgentSpec 等手段写清可允许的动作空间。

智能体时代并非一夜之间到来，而是以统一 API、协议标准、评测体系、AgentOps 与风险治理逐步堆叠的十年旅程。拥抱 Agent 之前，先让数

据、工具、流程、监控和人类团队准备好。